PUC Minas
A B A K Ó S
Instituto de Ciências Exatas e Informática

Licença Creative Commons Attribution 4.0 International

Análise Espacial de Ocupação em Espaços Controlados por Meio de Conexões Wi-Fi*

Abakós, Belo Horizonte, v. 1, n. 1, p. 01-17, Jun. 2025 - ISSN: 2316-9451

Ana Maria Ribeiro Rafael[1]
Arthur Silva Carvalho[2]
João Pedro Moura de Assis Filho[3]
Maicon Gomes Messias[4]
Gabriel Barbosa da Fonseca[5]
Marta Dias Moreira Noronha[6]

Resumo

Este artigo apresenta o desenvolvimento e a validação de um sistema de monitoramento de ocupação em espaços físicos por meio da análise de pacotes Wi-Fi. Utilizando roteadores com OpenWRT configurados em modo monitor, foi possível capturar passivamente sinais de dispositivos móveis para estimar padrões de movimentação. Os dados, tratados com técnicas de anonimização conforme a LGPD, foram processados por meio de um pipeline que inclui aprendizado de máquina e visualização geográfica, resultando em mapas de calor que representam a distribuição espacial da presença em ambientes simulados. Os experimentos, realizados em cenário controlado, indicaram que intervalos maiores de coleta proporcionam maior precisão, embora tenham evidenciado limitações de infraestrutura, como superaquecimento do roteador. O sistema, de baixo custo e baseado em software livre, demonstrou viabilidade técnica e potencial de replicação em ambientes corporativos e acadêmicos, com perspectivas futuras de ampliação da robustez e precisão.

*Artigo apresentado à Revista Abakos

[1]Bacharel em Engenharia de Computação, Instituto de Ciências Exatas e de Informática da PUC Minas, Brasil– amrrafael@sga.pucminas.br
[2]Bacharel em Engenharia de Computação, Instituto de Ciências Exatas e de Informática da PUC Minas, Brasil– arthurpad@hotmail.com
[3]Bacharel em Engenharia de Computação, Instituto de Ciências Exatas e de Informática da PUC Minas, Brasil– joaomoura11@yahoo.com.br
[4]Bacharel em Engenharia de Computação, Instituto de Ciências Exatas e de Informática da PUC Minas, Brasil– maicon.messias@sga.pucminas.br
[5]Professor(a) Orientador(a) TCC, Brasil– gabriel.fonseca@sga.pucminas.br
[6]Professor(a) Orientador(a) TCC, Brasil– marta.noronha@sga.pucminas.br

Palavras-chave: Monitoramento de Ocupação, Mapas de Calor, Espaços Controlados, Ambientes Controlados, Análise Espacial, Redes Wi-Fi, LGPD.

Abstract

This article presents the development and validation of an occupancy monitoring system for physical spaces through the analysis of Wi-Fi packets. Using routers with OpenWRT configured in monitor mode, it was possible to passively capture signals from mobile devices to estimate movement patterns. The data, processed with anonymization techniques in accordance with the LGPD, were handled through a pipeline that includes machine learning and geographic visualization, resulting in heatmaps that represent the spatial distribution of presence in simulated environments. The experiments, conducted in a controlled scenario, indicated that longer collection intervals provide greater accuracy, although infrastructure limitations, such as router overheating, were observed. The system, low-cost and based on free software, demonstrated technical feasibility and potential for replication in corporate and academic environments, with future perspectives for expanding robustness and precision.

Keywords: Occupancy Monitoring, Heatmaps, Controlled Environments, controlled spaces, Spatial Analysis, Wi-Fi Networks, LGPD.

1 INTRODUÇÃO

O monitoramento de ocupação em ambientes físicos por meio da análise de pacotes Wi-Fi tem se destacado como uma alternativa viável, não invasiva e baseada em infraestrutura amplamente disponível. A captação de sinais transmitidos por dispositivos móveis permite identificar padrões de movimentação e presença em espaços controlados, contribuindo para análises espaciais e geração de mapas de calor, em conformidade com a Lei Geral de Proteção de Dados (LGPD). Em ambientes acadêmicos, essa abordagem é particularmente útil para compreender a dinâmica de uso de salas e corredores, auxiliando na gestão de espaços, que é um desafio crescente em universidades. Trabalhos como o de Santana *et al.* (2022) apontam que a subutilização ou alocação inadequada de salas impacta diretamente a eficiência institucional, sendo necessário adotar soluções baseadas em tecnologia para apoiar esse processo. Estudos indicam que o uso de plataformas de gestão é essencial para otimizar esses ambientes, como destacado por Nakai, Fernandes e Pereira (2021). Este trabalho, no entanto, foca na construção de um sistema para coleta, tratamento e visualização da ocupação, visando a geração de dados confiáveis que possam fundamentar futuras análises e estratégias de otimização.

Com o avanço da Internet das Coisas (IoT), soluções tecnológicas baseadas em sensores e redes Wi-Fi estão sendo amplamente estudadas para monitorar o uso de salas. Pigatto, Nunes e Nicolete (2019) propõem uma integração da IoT nas salas de aula para monitoramento em tempo real através do gerenciamento por *fog computing*. Neto (2024) destaca o uso de microcontroladores, como o ESP32, para monitorar variáveis ambientais em salas limpas, uma abordagem que pode ser adaptada para o monitoramento de ocupação em instituições acadêmicas.

O monitoramento da ocupação de espaços por redes Wi-Fi pode ser uma solução acessível e menos invasiva em comparação com o uso de câmeras, respeitando a privacidade dos usuários. Nesse sentido, a Lei nº 13.709/2018, conhecida como Lei Geral de Proteção de Dados (LGPD) impõe desafios adicionais, exigindo que as instituições sigam rigorosamente as políticas de coleta, tratamento e anonimização de dados pessoais, conforme discutido em (NAKAI; FERNANDES; PEREIRA, 2021) e reforçado por estudos sobre gestão de espaços e infraestrutura acadêmica (SANTANA *et al.*, 2022).

Ferramentas de visualização de dados, como os modelos tridimensionais de edifícios, são úteis para mapear a ocupação e o uso de espaços. Zhao *et al.* (2023) investigam o uso de logs de conexão Wi-Fi para avaliar a ocupação em tempo real em um campus universitário, permitindo a análise precisa do fluxo de pessoas e Neto (2024) utiliza mapas de calor em ambientes de cassino para monitorar o fluxo de visitantes.

Para aumentar a eficiência do monitoramento, o uso de algoritmos de aprendizado de máquina em redes Wi-Fi tem sido explorado. Szott *et al.* (2022) exploram algoritmos de aprendizado de máquina, como o Q-learning, que podem otimizar o desempenho de redes IEEE 802.11, aprimorando a automação e a segurança em ambientes inteligentes. Essas técnicas facilitam a identificação de padrões de ocupação, permitindo uma gestão mais eficiente dos recursos

da rede e melhorando a experiência dos usuários. Silva, Senne e Lankalapalli (2012) propõem o uso de métodos de otimização cross-layer, uma abordagem que permite a coordenação entre diferentes camadas do modelo de rede para melhorar o desempenho do sistema. Esses métodos são adaptáveis a sistemas de monitoramento de ocupação, garantindo a eficiência na coleta e processamento de dados em tempo real. O uso de algoritmos para otimizar a alocação de salas de forma dinâmica também é explorado no estudo de Chandramohan *et al.* (2017), que aplica essa tecnologia em sistemas de automação residencial.

Em contexto de instituições acadêmicas, a infraestrutura de rede precisa ser robusta para suportar o grande volume de dados gerados por sistemas de monitoramento. Estudos indicam a importância de uma estrutura de cabeamento adequada e otimizada para garantir a estabilidade e eficiência das redes Wi-Fi em ambientes de grande fluxo (RODRIGUES *et al.*, 2023).

Outro aspecto relevante é o uso de sistemas de IoT para facilitar a tomada de decisões em locais essenciais. Conforme Melo (2024), a IoT permite o monitoramento em tempo real da ocupação, o que pode ser fundamental para o planejamento e a gestão de espaços. Além disso, Paulino (2017) destaca o uso de redes de sensores sem fio para monitoramento de variáveis em ambientes fechados, uma tecnologia que pode ser integrada ao monitoramento de ocupação para fornecer dados detalhados sobre o uso dos espaços.

A crescente adoção de tecnologias em instituições de ensino exigem uma abordagem que considere a transformação digital no aprendizado. Silva *et al.* (2024) abordam o papel da tecnologia na educação, destacando a importância de soluções que suportem a gestão eficiente dos espaços educacionais, alinhadas com as novas demandas pedagógicas, em consonância com a (UNESCO Office em Brasilia; IANNONE; SOARES, 2019).

O objetivo deste trabalho é desenvolver um sistema que utilize dados captados por redes Wi-Fi para monitorar o fluxo de pessoas em ambientes físicos, buscando otimizar a ocupação dos espaços e promover o uso eficiente dos recursos disponíveis. Para isso, são utilizadas tecnologias acessíveis, como redes Wi-Fi, aliadas à aplicação de métodos de anonimização, em conformidade com os requisitos da LGPD, garantindo a privacidade dos indivíduos e o cumprimento das regulamentações de proteção de dados como feito em (SANTOS; MOREIRA, 2022). O sistema desenvolvido também gera mapas de calor, que facilitam a visualização de como os espaços são utilizados ao longo do tempo. Por fim, espera-se que essa solução possa ser aplicada, futuramente, em diferentes tipos de ambientes e instituições, de forma mais ampla, possibilitando avaliar sua eficácia e seu potencial de uso em contextos variados e em maior escala.

Este trabalho está subdividido nas seguintes seções: Seção 2 apresenta a fundamentação teórica, abordando os conceitos essenciais relacionados a redes Wi-Fi, intensidade de sinal (RSSI), aprendizado de máquina e visualização com mapas de calor; a Seção 3 apresenta a revisão da literatura, reunindo estudos e abordagens relacionados ao monitoramento de ocupação com o uso de redes Wi-Fi, sensores e técnicas de aprendizado de máquina, além de destacar os principais desafios relativos à privacidade e à conformidade com a LGPD; a Seção 4 descreve a metodologia adotada, abordando a definição do ambiente de monitoramento, os materiais

utilizados, a configuração do roteador com OpenWRT em modo monitor, as estratégias de anonimização e os testes de eficiência do sistema em ambientes controlados; a Seção 5 detalha o processamento e a análise dos dados coletados, com uso de redes neurais treinadas com sinais RSSI, além da geração de mapas de calor sobre planta baixa vetorizada, consolidando os resultados obtidos ao longo do experimento; e, por fim, a Seção 6 apresenta a conclusão do estudo, destacando que o sistema proposto demonstrou viabilidade técnica em ambientes controlados, ainda que exija aprimoramentos para garantir maior precisão, estabilidade e escalabilidade em cenários mais complexos.

[1]

[1]Todos os códigos desenvolvidos estão disponíveis publicamente em nosso repositório de pesquisa: https://github.com/ICEI-PUC-Minas-EC-TCC/pmg-ec-2025-1-tcc2-mapa-de-calor

2 FUNDAMENTAÇÃO TEÓRICA

Nesta seção, são apresentados os conceitos fundamentais para o desenvolvimento do sistema proposto, abordando aspectos técnicos e teóricos sobre redes Wi-Fi, o indicador de intensidade de sinal RSSI, aprendizado de máquina e a geração de mapas de calor com dados espaciais.

2.1 Redes Wi-Fi e Coleta Passiva de Pacotes

As redes sem fio baseadas no padrão IEEE 802.11 são a base da conectividade em diversos ambientes. A comunicação entre dispositivos ocorre por meio da troca de pacotes, dentre os quais se destacam os *beacon frames*, transmitidos periodicamente pelos pontos de acesso, e os *probe requests* e *probe responses*, utilizados na descoberta de redes.

A coleta passiva permite a detecção da presença de dispositivos próximos apenas pela observação do tráfego no ar, sendo considerada uma abordagem não invasiva.

2.2 RSSI e Representação Espacial

O *Received Signal Strength Indicator* (RSSI) é uma métrica usada para expressar a potência de um sinal recebido, geralmente medida em decibéis-miliwatts (dBm), com valores negativos. Essa métrica é diretamente relacionada à distância entre o emissor e o receptor, sendo amplamente empregada em sistemas de localização e de estimativa de presença. Em ambientes internos, o RSSI é influenciado por obstáculos físicos, interferência eletromagnética e densidade de dispositivos, exigindo técnicas de suavização e agregação para uso confiável em análise espacial.

A relação entre RSSI e distância d pode ser modelada por meio da fórmula de perda de caminho em espaço livre, conhecida como modelo logarítmico:

$$RSSI(d) = RSSI_0 - 10 \cdot n \cdot \log_{10}(d)$$

onde:

- $RSSI(d)$ é o valor de intensidade de sinal no ponto d,
- $RSSI_0$ é a potência de sinal recebida a 1 metro do transmissor,
- n é o expoente de perda de caminho, que depende do ambiente (tipicamente entre 2 e 4 em interiores),
- d é a distância entre o transmissor e o receptor, em metros.

Essa equação ilustra como a intensidade do sinal decresce com a distância, e serve como base para estimativas de localização em sistemas que utilizam RSSI como variável de entrada.

2.3 Aprendizado de Máquina e Classificação de Zonas

O aprendizado de máquina supervisionado é um campo que visa treinar modelos a partir de dados rotulados, permitindo que façam previsões sobre novos dados. Redes neurais densas *(feed-forward)* são uma das estruturas mais utilizadas para tarefas de classificação, por sua capacidade de modelar relações complexas entre variáveis.

Nesse tipo de rede, as informações percorrem as camadas sequencialmente, da entrada até a saída, sem ciclos ou conexões recorrentes. Cada neurônio em uma camada realiza uma operação de combinação linear seguida de uma transformação não linear. Essa operação pode ser descrita matematicamente como:

$$z^{(l)} = W^{(l)}x^{(l-1)} + b^{(l)} \qquad a^{(l)} = f(z^{(l)})$$

em que:

- $x^{(l-1)}$ representa o vetor de ativações da camada anterior,
- $W^{(l)}$ é a matriz de pesos da camada l,
- $b^{(l)}$ é o vetor de vieses,
- f é a função de ativação, como a ReLU: $f(z) = \max(0, z)$,
- $a^{(l)}$ é a saída (ou ativação) da camada atual.

Esse mecanismo permite que a rede aprenda representações hierárquicas dos dados de entrada. A camada de saída, no caso de classificação multiclasse, aplica a função *softmax*:

$$softmax(z_i) = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$$

transformando os valores em uma distribuição de probabilidade entre as K classes possíveis. O modelo é então treinado para minimizar a discrepância entre as predições e os rótulos reais, normalmente utilizando a função de perda de entropia cruzada categórica.

Segundo Goodfellow, Bengio e Courville (2016), as redes *feed-forward* representam a forma mais básica de redes neurais profundas e servem como base para uma ampla variedade de arquiteturas mais complexas.

3 REVISÃO DA LITERATURA

A literatura sobre tecnologias para monitoramento de ocupação em espaços acadêmicos destaca soluções promissoras com base em redes sem fio e Internet das Coisas (IoT). Estudos como o de Almeida e Soares (2022) evidenciam os desafios impostos pela LGPD, apontando a necessidade de políticas rigorosas para tratamento de dados em instituições educacionais. O uso de microcontroladores de baixo custo, como o ESP32, é explorado por Neto (2024), que propõe a coleta em tempo real de variáveis ambientais, abordagem adaptável ao contexto acadêmico.

Trabalhos como o de Zhao *et al.* (2023) utilizam dados anonimizados de conexões Wi-Fi e modelos 3D para representar a ocupação em campus inteligentes, destacando o valor da visualização geoespacial na análise de movimentação. Este trabalho, por sua vez tem utiliza uso de infraestrutura simples e predição baseada em RSSI com mapas de calor e mapas de calor 2D com zonas vetorizadas. Já Silva, Senne e Lankalapalli (2012) propõem a otimização do desempenho de redes via métodos cross-layer, enquanto Chandramohan *et al.* (2017) exploram soluções acessíveis para automação e monitoramento em larga escala com Arduino e Wi-Fi. A integração de algoritmos de aprendizado de máquina com redes IEEE 802.11, como em Szott *et al.* (2022), complementa essa proposta ao evidenciar o potencial da IA na identificação de padrões de ocupação. Em outra vertente, Silva, Senne e Lankalapalli (2012) discutem a otimização de desempenho em redes sem fio por meio de técnicas *cross-layer*, destacando preocupações técnicas que também impactam a coleta de dados em sistemas baseados em Wi-Fi.

Esse trabalho alinha-se às abordagens citadas ao empregar redes Wi-Fi e princípios da IoT para monitoramento de ambientes físicos, com ênfase na geração de dados anonimizados e na visualização geoespacial das informações. Assim como em estudos anteriores, foram utilizados dados de RSSI capturados passivamente para estimar padrões de ocupação. Entretanto, o sistema se diferencia por propor uma arquitetura modular e de baixo custo, baseada em equipamentos acessíveis como roteadores com OpenWRT, sensores TP-Link e microcontroladores ESP32, além de um *pipeline* completo implementado com software livre.

4 METODOLOGIA

A metodologia adotada neste trabalho foi desenvolvida com o objetivo de implementar e validar um sistema de monitoramento de ocupação de ambientes por meio de redes Wi-Fi, utilizando equipamentos de baixo custo e ferramentas de software livre. O processo metodológico é estruturado em três etapas principais: (i) definição do fluxograma geral do sistema; (ii) descrição dos materiais utilizados com justificativa de uso; e (iii) detalhamento dos métodos aplicados, incluindo captura, processamento, visualização dos dados e garantia de conformidade com a LGPD.

4.1 Materiais Utilizados

Os materiais e tecnologias selecionados foram escolhidos com base na disponibilidade, custo e compatibilidade com o objetivo do estudo. A Tabela 1 apresenta um resumo dos componentes utilizados e a justificativa resumida para sua escolha.

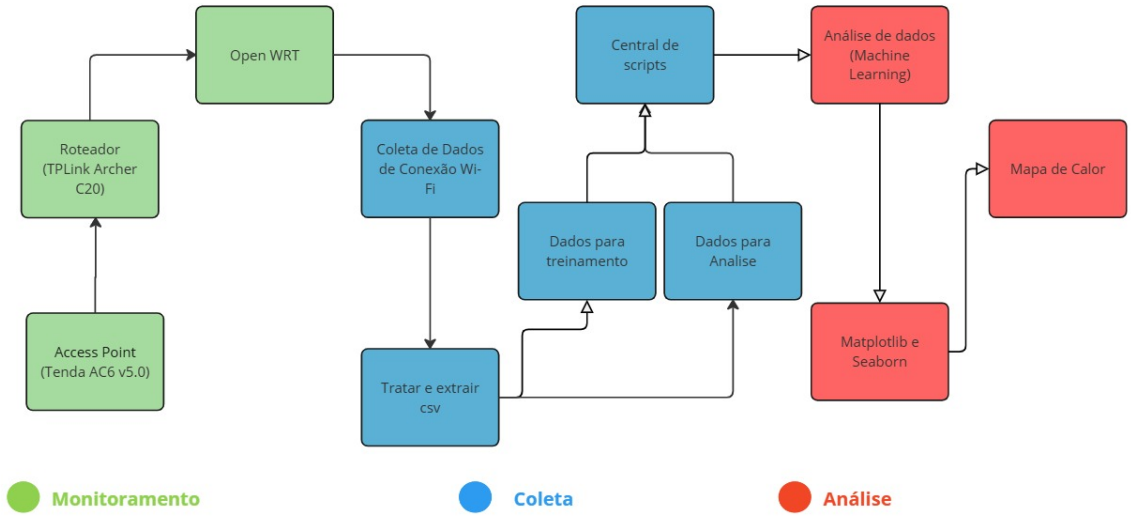
Tabela 1 – Materiais utilizados e justificativas

Item	**Justificativa de uso**
TP-Link Archer C20 com OpenWRT	Suporte a modo monitor e acesso root para captura passiva de pacotes Wi-Fi
Tenda AC6 v5.0 (Gateway/AP)	Suporte a DHCP e roteamento, permitindo acesso à Internet
Wireshark e OpenWRT/DD-WRT	Captura de pacotes 802.11 e controle do roteador via SSH
Python, Pandas, NumPy	Processamento, filtragem e manipulação dos dados de RSSI
TensorFlow e Scikit-Learn	Treinamento de modelos de machine learning para predição de zonas com base no sinal RSSI utilizando *feedforward*
Matplotlib e Seaborn	Geração de gráficos, mapas de calor e visualização sobre planta baixa
OpenCV e Scipy (Gaussian Filter)	Aplicação de suavização (blur) para interpolação visual dos mapas de calor
JSON	Armazenamento estruturado das zonas mapeadas e dos valores de RSSI por zona

4.2 Fluxograma do Processo Metodológico

A Figura 1 apresenta o fluxograma geral do sistema, representando as etapas desde a captura de pacotes Wi-Fi até a visualização e análise dos dados em forma de mapas de calor. Cada etapa corresponde a um dos objetivos do estudo, garantindo uma visão clara e modular da proposta.

Figura 1 – Fluxograma do processo metodológico



Fonte: Elaborado pelos autores.

4.3 Métodos

4.3.1 Ambiente de Monitoramento e Coleta de Dados

O Ambiente de Monitoramento e Coleta de Dados foi estabelecido conforme descrito no fluxograma apresentado na Figura 1, englobando as etapas de monitoramento, captura e análise das informações de rede. A estrutura proposta define os principais componentes e suas interações, assegurando a organização necessária para a execução eficiente das atividades de coleta de sinais Wi-Fi em ambiente controlado.

A arquitetura do sistema de monitoramento foi estruturada a partir de um roteador TP-Link Archer C20 com firmware OpenWRT, configurado para atuar como ponto central de escuta em modo monitor. Além dele, um roteador adicional, Tenda AC6 (gateway da rede), foi posicionado como ponto de acesso (AP), permitindo a conectividade de dispositivos e criando um ambiente controlado para a coleta dos sinais Wi-Fi. A captura dos pacotes foi realizada remotamente via SSH utilizando o utilitário `tcpdump`, com redirecionamento da saída para arquivos `.pcap` armazenados localmente no roteador e posteriormente transferidos via `scp` para a estação de coleta.

Para auxiliar na análise comparativa da intensidade do sinal RSSI, foram posicionados dispositivos com IP fixo em locais estratégicos, como notebooks, microcontroladores e smartphones. Esses dispositivos foram tratados como *IPs âncora*, atuando como referência de

localização e sinal.

O processamento dos arquivos foi realizado por meio de um script em Python desenvolvido com o uso da biblioteca PyShark, cuja funcionalidade é similar à do Wireshark, uma ferramenta de análise de pacotes que permite capturar, inspecionar e diagnosticar o tráfego de redes em tempo real. Esse software, descrito em Soepeno (2023), é amplamente utilizado na análise de pacotes de rede. Esse script foi executado inicialmente em um contêiner Docker com imagem baseada em `python:3.11-slim`, contendo dependências como `tshark`, `mysql-connector`, `pandas` e `numpy`. Para facilitar a manutenção e o isolamento dos serviços, foi utilizado um arquivo `docker-compose.yml` com os serviços `app` (processamento) e `mysql` (armazenamento), ambos com volumes persistentes. Em fases posteriores de testes, o script foi adaptado para execução diretamente no host (Ubuntu), utilizando ambiente virtual Python e redirecionando os dados extraídos para arquivos texto no formato estruturado `dados.txt`, o que facilitou a validação e depuração do sistema.

4.3.2 Configuração do OpenWRT e Interface de Captura

O roteador TP-Link Archer C20 foi escolhido por ser compatível com o firmware *OpenWRT*, que permite acesso *root* ao sistema e suporte ao modo monitor, essencial para a escuta passiva de pacotes Wi-Fi 802.11. Embora não seja necessariamente o modelo mais utilizado em ambientes escolares, sua seleção se justifica pela ampla disponibilidade no mercado, baixo custo e, principalmente, pela facilidade de modificação e suporte à captura em modo monitor. Essas características tornam o dispositivo adequado para replicações em ambientes educacionais com infraestrutura limitada, alinhando-se ao objetivo do trabalho de propor uma solução acessível e aplicável ao contexto escolar. A configuração da captura foi feita a partir da criação de uma interface virtual dedicada (`mon0`), derivada da interface física `phy0`. Essa interface foi ativada com os comandos `iw phy phy0 interface add mon0 type monitor` seguido de `ip link set mon0 up`, permitindo que o roteador escutasse todos os pacotes trafegados no ar, mesmo sem estar associado a nenhuma rede. A captura foi realizada com o `tcpdump` utilizando filtros e parâmetros como truncamento de pacotes (`-s 0`) e rotação por tempo (`-G 60 -W 1`), ajustados com a remoção de dados como valores positivos e nulos, para garantir a integridade dos dados mesmo com limitações de memória do dispositivo. Devido à ausência do serviço

Devido à ausência do serviço `sftp-server` no OpenWRT, que é o componente responsável por permitir a transferência segura de arquivos via protocolo SFTP (SSH File Transfer Protocol), não foi possível realizar a cópia remota utilizando esse método. Como alternativa, o protocolo SCP foi utilizado com o parâmetro `-O`, forçando a compatibilidade para a transferência dos arquivos capturados à estação de análise. Essa configuração permitiu a coleta contínua e discreta de pacotes do tipo *beacon frame*, *probe request* e *probe response*, fundamentais para estimar a presença e movimentação de dispositivos no ambiente. Os *beacon frames* são pacotes

transmitidos periodicamente pelos pontos de acesso para anunciar sua presença e informações básicas da rede. Já os *probe requests* são enviados por dispositivos clientes em busca de redes disponíveis, enquanto os *probe responses* são respostas dos pontos de acesso a essas sondagens, contendo detalhes da rede detectada. A escuta passiva desses pacotes permite identificar dispositivos próximos, mesmo sem conexão ativa à rede.

4.3.3 Privacidade e LGPD

Considerando as diretrizes da LGPD, o presente trabalho foi desenvolvido com atenção especial à conformidade legal, adotando práticas de minimização de dados e anonimização. Durante a coleta e o processamento dos pacotes Wi-Fi, foram armazenados apenas dois campos: o endereço MAC de origem e o valor de intensidade de sinal (RSSI), suficientes para estimar padrões de presença e movimentação no ambiente. Nenhuma informação sensível, pessoal ou que permita a identificação direta do usuário foi registrada.

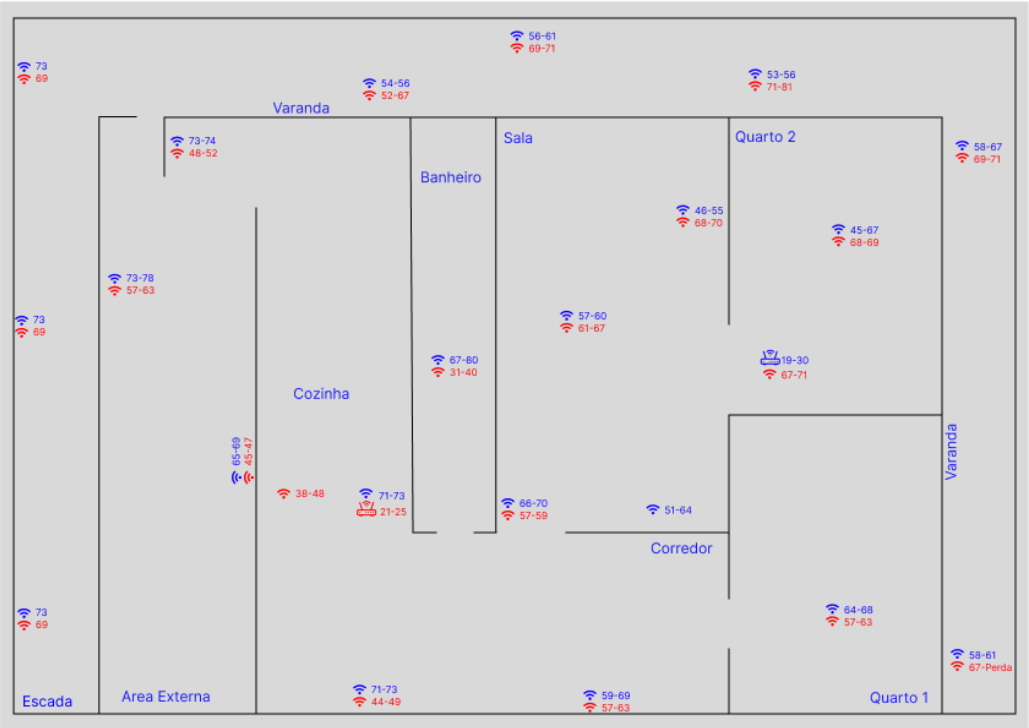
A anonimização foi garantida por meio da aplicação de filtros durante o processo de captura e análise, que descartam dados potencialmente sensíveis, como nomes de servidores acessados (extraídos de pacotes DNS) ou identificadores de redes específicas (SSID ou hostname de dispositivos), que poderiam expor a identidade ou os hábitos de navegação dos usuários. Dessa forma, assegura-se que os dados coletados não permitam, nem direta nem indiretamente, a identificação de indivíduos.

4.3.4 Avaliação do Comportamento do Sistema

Para compreender o comportamento do sistema proposto, foram realizados testes em dois cenários: inicialmente em ambiente controlado e, posteriormente, em um espaço real com circulação de pessoas. O objetivo foi verificar a correspondência entre os dados capturados, com foco nos valores de RSSI, e a ocupação real do ambiente monitorado. Utilizaram-se diferentes intervalos de tempo para a coleta de dados, de 1 e 5 minutos, o que permitiu observar o desempenho do sistema em diferentes janelas de observação, identificando padrões de presença, movimentação e eventuais perdas de pacotes em coletas mais longas.

O ambiente de testes foi escolhido por apresentar características estruturais semelhantes às de ambientes acadêmicos e administrativos, como paredes internas, corredores e múltiplas salas. Conforme ilustrado na Figura 2, foram distribuídos dispositivos como smartphones, notebooks e microcontroladores ESP32, todos com IP fixo, em pontos estratégicos do espaço. Essa configuração possibilitou a comparação direta entre os valores de RSSI capturados por um roteador em modo monitor e a posição física dos dispositivos. A simulação também permitiu observar variações provocadas por barreiras físicas e movimentação dos indivíduos, contribuindo para ajustes nos parâmetros de coleta e o refinamento da lógica de análise espacial.

Figura 2 – Layout do ambiente de testes com a distribuição dos dispositivos.



Fonte: Elaborado pelos autores.

4.3.5 Análise e Processamento dos Dados com IA

De modo similar ao descrito por Zanona E. C. (2010), ferramentas de medição de sinal e geração de mapas de calor 2D foram incorporadas em nossa metodologia para avaliar cobertura e interferências espaciais. O sistema foi desenvolvido com uma arquitetura modular composta por cinco elementos principais: *"gerar_mp_rssi.py"*, *"desenhar_mp_zonas.py"*, *"zonas_salvas.json"*, *"modelo_rssi_tflow.py"* e *"mp_calor_kerasC.py"*.

A primeira etapa consistiu na definição das zonas físicas sobre a planta baixa, associando-as a coordenadas vetoriais salvas em *"zonas_salvas.json"*, que passaram a servir de referência para o mapeamento espacial dos dados. Em seguida, os valores médios de intensidade de sinal (RSSI) observados em cada zona, provenientes dos roteadores Tenda e Archer, foram obtidos em testes controlados e registrados no arquivo *"rssi_por_zona.json"*.

A etapa de aprendizado de máquina foi implementada por meio de uma rede neural densa *(feed-forward)* utilizando *TensorFlow*, e não por métodos baseados em árvore de decisão. O script *modelo_rssi_tflow.py* executa o treinamento com vetores de entrada contendo dois atributos (RSSI de cada roteador), que foram normalizados com o *MinMaxScaler*, ferramenta que ajusta os valores para o intervalo entre 0 e 1, garantindo maior estabilidade numérica durante o treinamento. Os rótulos das zonas foram convertidos em valores inteiros com o *LabelEncoder*, permitindo que categorias nominais fossem interpretadas adequadamente pelo modelo. A arquitetura da rede inclui duas camadas ocultas com 64 neurônios cada e ativação *ReLU*, seguidas

de uma camada de *dropout* com taxa de 30 por cento para controle de sobreajuste. A camada de saída utiliza a função de ativação *softmax*, que retorna a probabilidade de ocorrência para cada zona mapeada.

O treinamento utilizou o otimizador Adam, com taxa de aprendizado de 0,001, durante 50 épocas e em lotes de oito amostras, sobre um conjunto de 20 mil registros coletados em um intervalo de cinco minutos. Testes com diferentes taxas de *dropout* (0,0; 0,2; 0,3; 0,4) foram realizados para calibrar a estabilidade do modelo.

O modelo treinado foi salvo como *"modelo_rssi_tflow.keras"* e aplicado sobre o conjunto completo de dados (*"dados.csv"*), permitindo estimar a zona mais provável para cada registro de sinal. Com métodos similares aos descritos por Oliveira *et al.* (2022) e Rodrigues, Ferreira e Gomes (2025), os scripts *"gerar_mp_rssi.py"* e *"mp_calor_kerasC.py"* consolidam as predições em mapas de calor suavizados sobre a planta vetorizada. Essa etapa é automatizada por *"desenhar_mp_zonas.py"*, possibilitando a visualização espacial da ocupação com base exclusivamente nos pacotes Wi-Fi capturados.

4.3.6 Geração de Mapas de Calor e Visualização

A visualização espacial dos resultados foi realizada com base na predição das zonas mais prováveis para cada registro de RSSI. O script *"mapa_calor_kerasC.py"* foi responsável por consolidar essas previsões em mapas de calor sobre a planta baixa, com zonas coloridas proporcionalmente à frequência de detecção. Para garantir a clareza visual, foram aplicadas técnicas de suavização com *"Gaussian blur"*, resultando em mapas de calor difusos com gradações mais naturais. A intensidade das cores segue o colormap *"coolwarm"*, atribuindo tons azuis para regiões com menor atividade e tons vermelhos para áreas com maior concentração de presença.

5 ANÁLISE E DISCUSSÃO DOS RESULTADOS

Para a etapa final do projeto, foi conduzido um experimento com seis participantes em um ambiente previamente mapeado, replicando as condições simuladas nos testes de desenvolvimento. Três dispositivos foram conectados ao roteador Archer C20 e outros três ao roteador Tenda AC6, utilizando os endereços MAC previamente identificados. Os participantes circularam pelos cômodos conforme planejamento prévio, e os dados foram coletados em dois intervalos distintos: 1 minuto (com aproximadamente 1 mil registros) e 5 minutos (com cerca de 100 mil registros). Foi estabelecido que cada participante deveria se deslocar por no mínimo duas áreas mapeadas. Essa configuração foi importante para garantir uma variação espacial significativa e permitir uma avaliação consistente dos resultados gerados pelo modelo de aprendizado de máquina utilizado na criação dos mapas de calor. Caso não houvesse registros de movi-

mentação, ou se a movimentação ocorresse apenas em áreas sem cobertura de sinal, eventuais falhas na estimativa seriam visíveis visualmente nos mapas, comprometendo a análise espacial proposta.

5.1 Desafios Técnicos

Durante a preparação do experimento final, foram enfrentados desafios técnicos relevantes. A configuração do roteador Archer C20 com OpenWRT exigiu uma conexão alternativa, uma vez que a rede realizava bloqueios a conexão direta por causa das configurações da operadora. A solução encontrada foi a utilização de um modem externo, garantindo acesso remoto via SSH e continuidade da coleta. Observou-se também que, durante a coleta de pacotes com o utilitário `tcpdump`, houve significativa redução de desempenho na rede, afetando dispositivos conectados ao ponto de acesso auxiliar.

Além disso, durante coletas mais longas, como a de 5 minutos, o roteador principal apresentou instabilidade e parou de responder às conexões SSH, indicando provável superaquecimento causado pelo uso prolongado em modo monitor. Outro possível fator que pode ter contribuído para a instabilidade é a limitação de recursos do dispositivo, como processamento e memória, que são exigidos intensamente durante a captura contínua de pacotes.

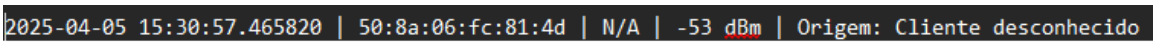
Essas limitações evidenciaram a importância da adoção de estratégias de resfriamento e a necessidade de utilizar equipamentos mais robustos em aplicações reais. Foram observadas ainda falhas na detecção em zonas com baixa cobertura e confusão entre zonas adjacentes com sinais semelhantes de RSSI, o que comprometeu a precisão de algumas predições.

Uma possível solução para contornar o problema de aquecimento é a adoção de modificações no hardware que possibilitem a instalação de um sistema de resfriamento, como dissipadores de calor ou ventoinhas USB, além da programação de coletas em intervalos, evitando o uso contínuo do equipamento.

5.2 Execução da Coleta e Extração dos Dados

Nessa etapa, a biblioteca PyShark foi empregada para processar os arquivos e extrair os campos essenciais para análise: endereço MAC de origem, intensidade do sinal (RSSI) e o instante da captura (*timestamp*). Esses dados foram armazenados em arquivos texto estruturados para facilitar a validação e a visualização. A Figura 3 ilustra um exemplo dos registros extraídos, com destaque para os diferentes dispositivos identificados e seus respectivos níveis de sinal coletados ao longo do tempo.

Figura 3 – Visualização de endereços MAC e valores de RSSI extraídos do arquivo `capture.pcap`.



Fonte: Elaborado pelos autores.

Durante o processo de coleta, os dados foram capturados em tempo real e armazenados em arquivos, a partir dos quais foram extraídas as informações anteriormente mencionadas. Os registros extraídos foram convertidos para arquivos de texto estruturados, servindo como base para o modelo de aprendizado de máquina implementado com *TensorFlow*. A associação entre os dispositivos monitorados e seus respectivos pontos de acesso pode ser observada na Tabela 2, que reflete a organização dos participantes no ambiente de teste.

Tabela 2 – Distribuição dos participantes por roteador no experimento final

Endereço MAC	Ponto de Acesso
50:8a:06:fc:81:4d	Tenda
22:55:7E:84:10:17	Tenda
4A:E9:21:8B:E1:CE	Tenda
52:9F:14:D9:81:25	Archer
30:cc:21:14:be:83	Archer
56:4b:54:3b:84:8f	Archer

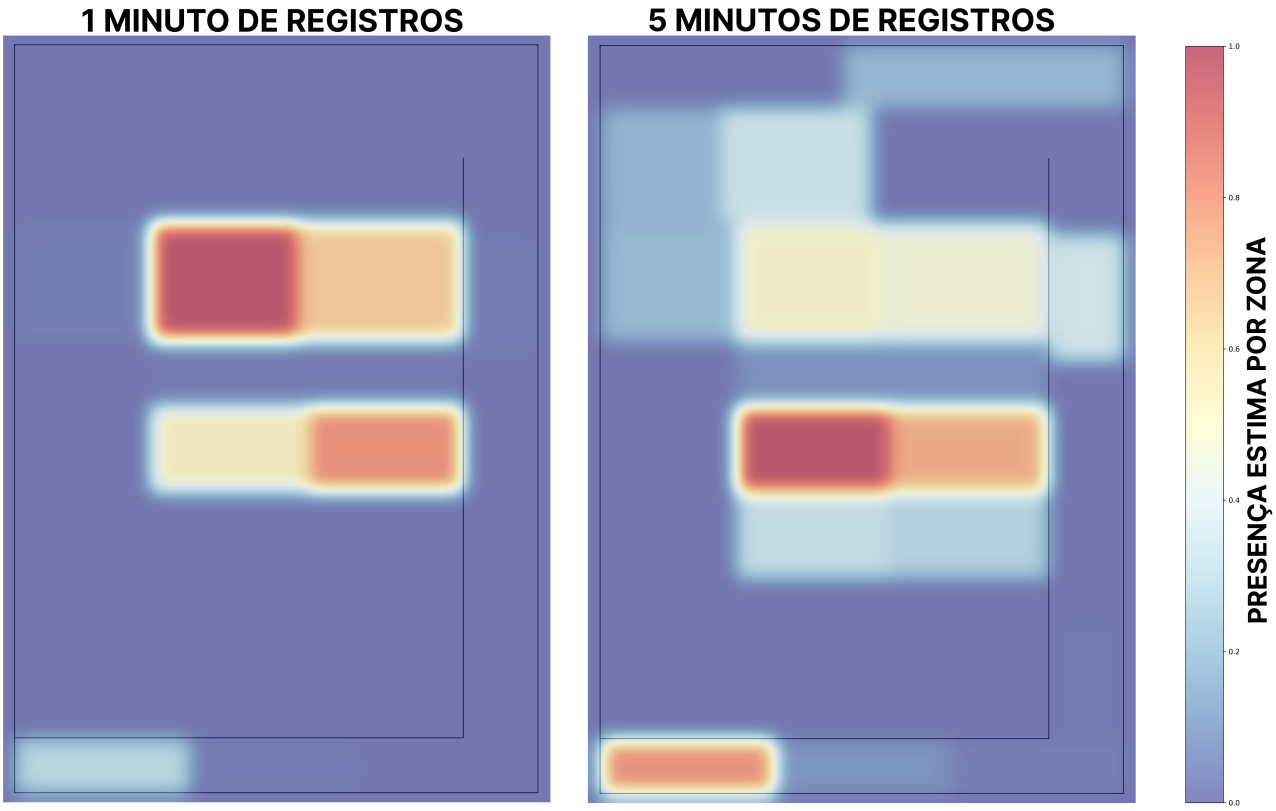
Fonte: Elaborado pelos autores.

5.3 Análise dos Resultados

Os dados foram utilizados para gerar mapas de calor sobre planta baixa vetorizada, representando a concentração de dispositivos em diferentes zonas. A Figura 4 mostra o comparativo entre os mapas produzidos com 1 minuto e 5 minutos de coleta. O mapa de 5 minutos apresentou maior densidade e precisão na estimativa das zonas ocupadas, reforçando a importância de coletas mais longas para robustez analítica.

No entanto, a coleta prolongada trouxe consequências técnicas, como o já citado superaquecimento do roteador e o risco de falhas operacionais. Adicionalmente, a análise revelou que em áreas de passagem rápida o sistema tendia a superestimar a ocupação, devido à presença de picos de sinal momentâneos. Para resolver essa questão, foram sugeridos filtros que considerem o tempo de permanência em cada zona, descartando pacotes de curta duração. Com esses ajustes, foi possível melhorar a acurácia dos mapas de calor, é esperado que a aplicação seja mais eficiente em cenários de alto fluxo.

Figura 4 – Comparativo dos mapas de calor gerados com cerca de 1 mil registros (1 minuto, à esquerda) e 100 mil registros (5 minutos, à direita).



Fonte: Elaborado pelos autores

6 CONCLUSÃO

De forma geral, o sistema proposto demonstrou ser funcional, modular e eficaz para ambientes internos controlados. A combinação entre a coleta passiva de pacotes Wi-Fi, técnicas de aprendizado de máquina e visualização geográfica permitiu transformar dados brutos em mapas de ocupação. Os testes realizados em ambiente experimental confirmaram a viabilidade da solução, especialmente na identificação de áreas com maior permanência e movimentação de dispositivos ao longo do tempo.

Os resultados obtidos atenderam às expectativas iniciais, mostrando que a abordagem é capaz de mapear padrões de ocupação de forma aplicável, caso o ambiente aonde será feita a implementação seja previamente mapeado. A utilização de softwares de código aberto e scripts personalizados possibilitou uma implementação consideravelmente com baixo custo econômico, com potencial de replicação. Em um cenário controlado, foi possível acompanhar claramente o deslocamento dos participantes, reforçando a capacidade do sistema em captar padrões reais de presença e fornecer uma base para análises espaciais.

No entanto, a aplicação em contextos mais amplos ainda exige alguns aprimoramentos. A precisão do sistema pode ser impactada por fatores como a densidade do sinal e a interferência

entre zonas próximas, o que pode gerar erros na identificação de áreas específicas. Além disso, observou-se que o uso prolongado do roteador em modo monitor causou superaquecimento, comprometendo a estabilidade do sistema em coletas de longa duração.

Dessa forma, embora os resultados obtidos em ambientes controlados tenham sido positivos, o sistema ainda demanda ajustes técnicos e metodológicos para alcançar um desempenho estável e confiável em cenários mais complexos. A consolidação dessa solução passa pelo refinamento dos algoritmos de predição, pela melhoria da infraestrutura utilizada e pelo fortalecimento do processo de coleta de dados, visando garantir a maior precisão e sustentabilidade operacional.

Para trabalhos futuros, propõe-se a expansão do sistema para ambientes maiores e mais variados, com múltiplos pontos de coleta estrategicamente distribuídos. A utilização de locais com refrigeração adequada pode contribuir para mitigar o problema de aquecimento dos equipamentos durante coletas prolongadas. Além disso, recomenda-se a integração de outros métodos de gerenciamento de ocupação, como sensores de presença, e a aplicação de técnicas de triangulação, viáveis com a estrutura já desenvolvida por meio da adição de mais roteadores operando simultaneamente em modo monitor. Também é pertinente explorar a aplicação do sistema em áreas externas ou de maior circulação, como corredores e momentos de intervalo em instituições de ensino superior, ainda que de forma preliminar, visando ampliar a validade do estudo em cenários mais amplos e dinâmicos.

REFERÊNCIAS

ALMEIDA, S. d. C. D. d.; SOARES, T. A. Os impactos da lei geral de proteção de dados-lgpd no cenário digital. **Perspectivas em Ciência da Informação**, SciELO Brasil, v. 27, p. 26–45, 2022. ISSN 1981-5344. Disponível em: <https://www.scielo.br/j/pci/a/tb9czy3W9RtzgbWWxHTXkCc/>. Acesso em: 13 de mar. 2025.

CHANDRAMOHAN, J. *et al.* Intelligent smart home automation and security system using arduino and wi-fi. **International Journal of Engineering And Computer Science (IJECS)**, v. 6, n. 3, p. 20694–20698, 2017.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.l.]: MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org/>. Acesso em: 28 de jun. 2025.

MELO, L. d. **IoT para monitoramento em tempo real da ocupação em locais essenciais para facilitar a tomada de decisões**. February 2024. TCC (graduação) — Universidade Federal de São Carlos, São Carlos, SP, Brasil, February 2024. Disponível em: <https://repositorio.ufscar.br/handle/ufscar/19387/>. Acesso em: 13 de mar. 2025.

NAKAI, C. C. H.; FERNANDES, J. E.; PEREIRA, M. J. Plataforma de gestão de espaços numa escola de ensino superior. In: **16th Iberian Conference on Information Systems and Technologies (CISTI)**. [S.l.]: IEEE, 2021. p. 1–6. ISBN 978-989-54659-1-0.

NETO, M. M. d. L. Trabalho de Conclusão de Curso (Graduação), **Monitoramento de parâmetros em "salas limpas" usando o microcontrolador ESP32**. Natal, RN: [s.n.], 2024. Disponível em: <https://repositorio.ufrn.br/items/1facea5e-7fb8-4eb6-afde-94b7d8c77d6b>. Acesso em: 03 de mar. 2025.

OLIVEIRA, L. F. d. *et al.* Caminhabilidade, requalificação e digitalidade: avaliação do campus da ufsc amparado por dados digitais. Florianópolis, SC, 2022. Disponível em: <https://repositorio.ufsc.br/handle/123456789/240265>. Acesso em: 04 de abr. 2025.

PAULINO, M. L. **Monitoramento e gestão de variáveis em ambiente fechado por meio de rede de sensores sem fio (RSSF)**. November 2017. Dissertação (Dissertação de Mestrado) — Pontifícia Universidade Católica de Campinas, Centro de Ciências Exatas, Ambientais e de Tecnologias, Campinas, SP, Brasil, November 2017. Orientador: Carvalho, Marcius Fabius Henriques de. Disponível em: <https://repositorio.sis.puc-campinas.edu.br/handle/123456789/15073/>, Acessado em: 03 de abr de 2025.

PIGATTO, L. d. S.; NUNES, F. B.; NICOLETE, P. C. Proposta de integração da iot à sala de aula com gerenciamento por fog. **International Journal of Knowledge Engineering and Management**, v. 8, n. 21, p. 59–79, 2019. ISSN 2316-6517. Disponível em: <https://publicacoes.rexlab.ufsc.br/index.php/sited/article/view/88>. Acesso em: 03 de jun. 2025.

RODRIGUES, N. *et al.* Otimização da estrutura do cabeamento estruturado e gerenciamento da rede: estudo de caso empresa rotesma. **Observatorio de la Economía Latinoamericana**, v. 21, n. 9, p. 11753–11775, 2023. ISSN 1696-8352. Disponível em: <https://www.researchgate.net/publication/374036369>. Acesso em: 03 de jun. 2025.

RODRIGUES, R. F.; FERREIRA, F. C. L.; GOMES, D. d. A. Análise de logs de rede sem fio com suporte à tomada de decisão na infraestrutura de tecnologia da informação. **Revista Brasileira de Criminalística**, v. 14, n. 1, p. 30–45, 2025. Disponível em: <https://www.researchgate.net/publication/390357412>. Acesso em: 01 de jun. 2025.

SANTANA, R. *et al.* Otimização da alocação de salas de aula: um estudo de caso na universidade federal de são carlos. **Pesquisa Operacional para o Desenvolvimento**, v. 15, p. 1–18, 2022. Disponível em: <http://repositorio.ufsm.br/handle/1/4751>. Acesso em: 26 de jun. 2025.

SANTOS, L. H.; MOREIRA, J. Desafios pessoais nos incidentes de segurança e vazamentos de dados em redes wi-fi públicas sob o escopo da lgpd. In: **Anais do Encontro Nacional de Produção e Ensino (ENPE)**. [S.l.: s.n.], 2022. p. 1–15. ISSN 2358-5064. Disponível em: <http://enpe.ptc.iftm.edu.br/index.php/enpe/article/view/341>. Acesso em: 04 de abr. 2025.

SILVA, C. S. *et al.* A era digital na educação: o papel transformador da tecnologia no aprendizado. **Educação**, v. 28, n. 138, September 2024. ISSN 1678-0817. Disponível em: <https://revistaft.com.br/a-era-digital-na-educacao-o-papel-transformador-da-tecnologia-no-aprendizado/>. Acesso em: 03 de jun. 2025.

SILVA, M. da; SENNE, E. L. F.; LANKALAPALLI, N. Métodos de otimização cross-layer em ambientes multimídia aplicados em redes sem fio em malha. In: **Anais do XXXIV Simpósio Brasileiro de Redes de Computadores e Sistemas Distribuídos (SBRC)**. Curitiba, PR, Brasil: Sociedade Brasileira de Computação, 2012. p. 1–12. Disponível em: <http://mtc-m16c.sid.inpe.br/col/sid.inpe.br/mtc-m18/2012/12.17.12.08/doc/worcap2012_submission_62%20-%20Marlon%20da%20Silva.pdf>. Acesso em: 03 de jan. 2025.

SOEPENO, R. A. A. P. Wireshark: An effective tool for network analysis. **Unpublished report**, 2023. Disponível em: <https://www.researchgate.net/publication/374675769>. Acesso em: 03 de jun. 2025.

SZOTT, S. *et al.* Wi-fi meets ml: A survey on improving ieee 802.11 performance with machine learning. **IEEE Communications Surveys & Tutorials**, v. 24, n. 3, p. 1843–1893, 2022. ISSN 1553-877X. Disponível em: <https://ieeexplore.ieee.org/document/9786784>. Acesso em: 16 de fev. 2025.

UNESCO Office em Brasilia; IANNONE, L. R.; SOARES, A. C. **Gestão da educação pública com uso de tecnologia digital: características e tendências**. Brasília, Brasil: UNESCO, 2019. 245 p. CC BY-SA 3.0 IGO. ISBN 978-85-7652-248-5.

ZANONA E. C., . B. E. Ferramenta para suporte à atividade de site survey em redes sem fio. **Revista Eletrônica de Iniciação Científica**, FATEC-SP, v. 7, n. 1, p. 1–10, 2010. Disponível em: <https://revistaseletronicas.pucrs.br/graduacao/article/view/7889>. Acesso em: 23 de mar. 2025.

ZHAO, Z. *et al.* Geo-visualization of spatial occupancy on smart campus using wi-fi connection log data. **ISPRS International Journal of Geo-Information**, MDPI, v. 12, n. 11, p. 455, 2023. ISSN 2220-9964. Acesso em: 23 de mai. 2025.